# Мультимодальные RAG модели

Поиск по документам



MISIS\_Is All You Need

### Почему это важно?

### Необходимость улучшения пользовательского опыта

Пользователи ожидают интуитивно понятных и быстрых решений для поиска информации.

### Большой объем данных

В современных организациях объем документов и информации постоянно растет, что затрудняет их эффективный поиск и использование.

### Низкая эффективность традиционных методов

Существующие методы поиска часто не учитывают контекст и семантику, что приводит к низкой точности результатов.

### Много разныхформатов

Документы могут быть представлены в различных форматах (текстовые файлы, изображения, PDF и т.д.), что усложняет процесс их индексации и поиска.

## Что есть на рынке?













Ограниченные возможности интеграции

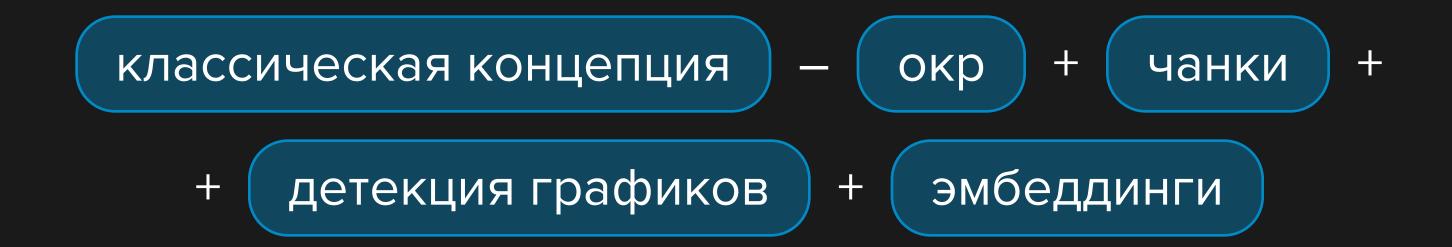
Сложность в использовании

Ограниченные функции поиска

Ограниченные возможности настройки

Высокая стоимость и малый пробный период

Доступ и контент для узкого круга лиц



### ColPali & Qwen

как объединение новой и классической концепции вижн ретривала документов

# ColPali

- о Квантизация вместе с соответствующей квантованной базой данных для консистентного инференса
- о Возможность дообучения модели на выданных данных данных для улучшения перформанса на узком домене пула документов
- о Адаптивное удаление нерелевантных документов, не соответствующих по схожести ни одному эталонному документу
- Удаление документов по айди по желанию юзера
- о Принимает pdf & docx

- о Эффективная утилизация гпу памяти с динамическим очищением
- Возможность корректировать time-memory tradeoff инференса модели под имеющиеся условия

# QWen

- о Баланс между ответом в онлайне на запрос оффлайн описанием картинки для РАГ подхода
- о Адаптивный чанкинг текста и графиков документа + детекция с document yolo & clustering

Размер модели в 4-7 раз меньше других моделей, подходящих для данных целей

# Принцип работы

### Первая реализация

Получение файла  $\rightarrow$  Разделение на слайды картинки  $\rightarrow$  Получение embeddings из ColPali  $\rightarrow$ 

Coxpaнeние эмбедингов в Qdrant

Пользователь вводит запрос  $\rightarrow$  (Переводим в embedding вопрос user  $\rightarrow$ 

находим самый близкий слайд из БД Qdrant

Используем Qwen для ответа на вопрос user

Выдаём ответ

Результат не углублённый, местами не точный

# Принцип работы

### Вторая реализация

Пользователь вводит запрос 

Находим самый близкий слайд и БД Qdrant 

С помощью библиотеки doclayout-yolo разделяем слайд на: текст картинки графики таблицы 

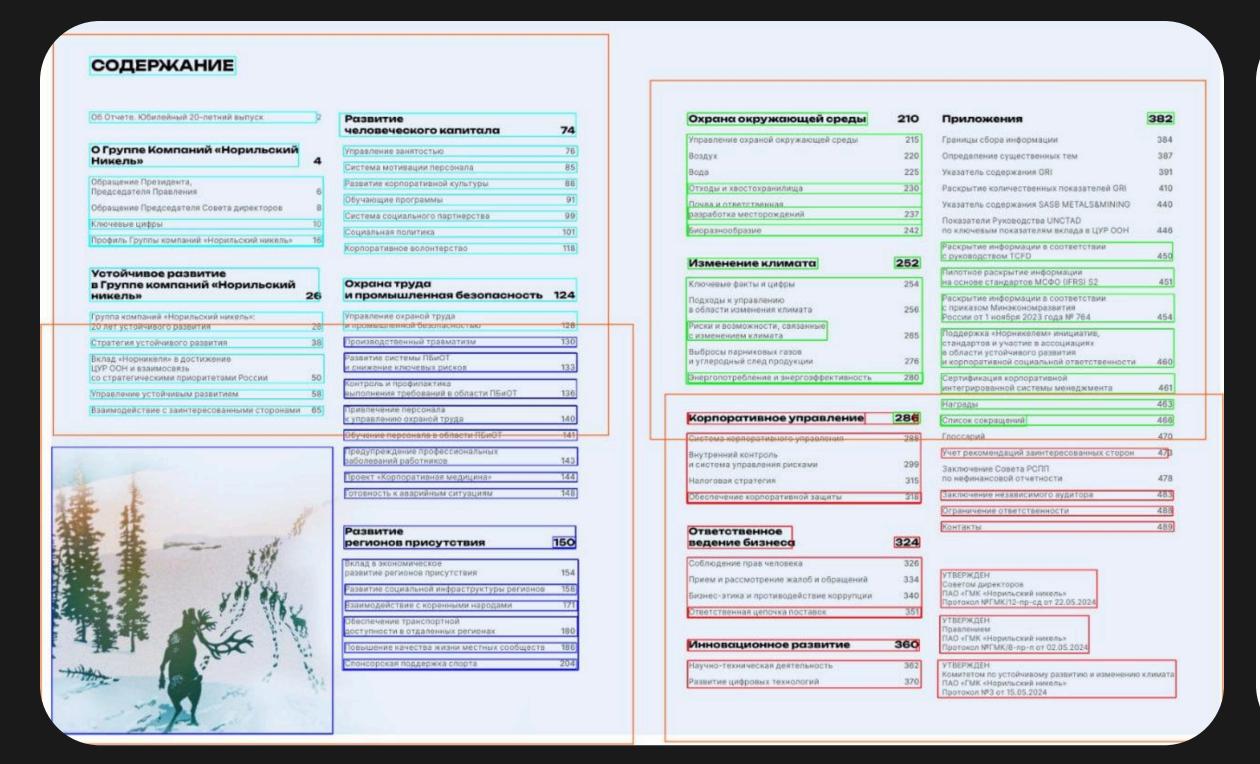
Делаем кластеризацию на 4 класса 

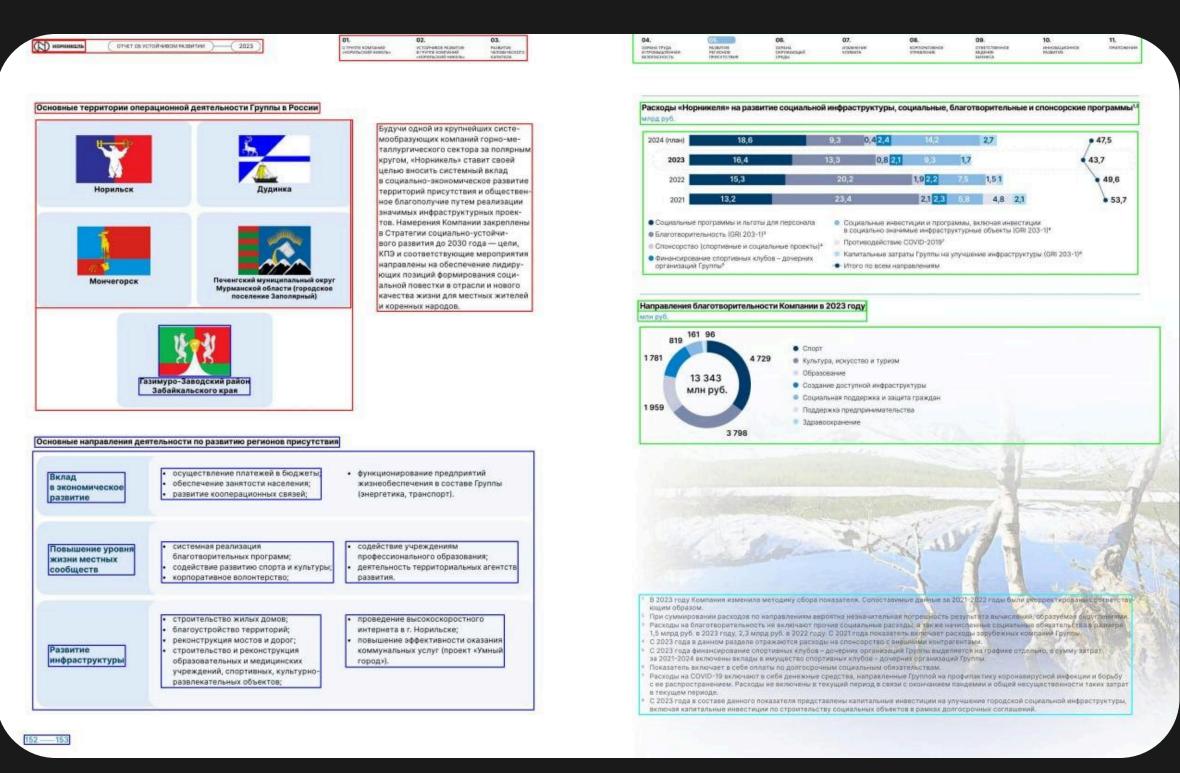
Вырезаем 4 фрагмента текста 

Обрабатываем каждый из фрагментов Qwen чтобы она описала картинку/текст (а не дала ответ)

Обрабатываем каждый из фрагментов Qwen ответ

Выдаём ответ

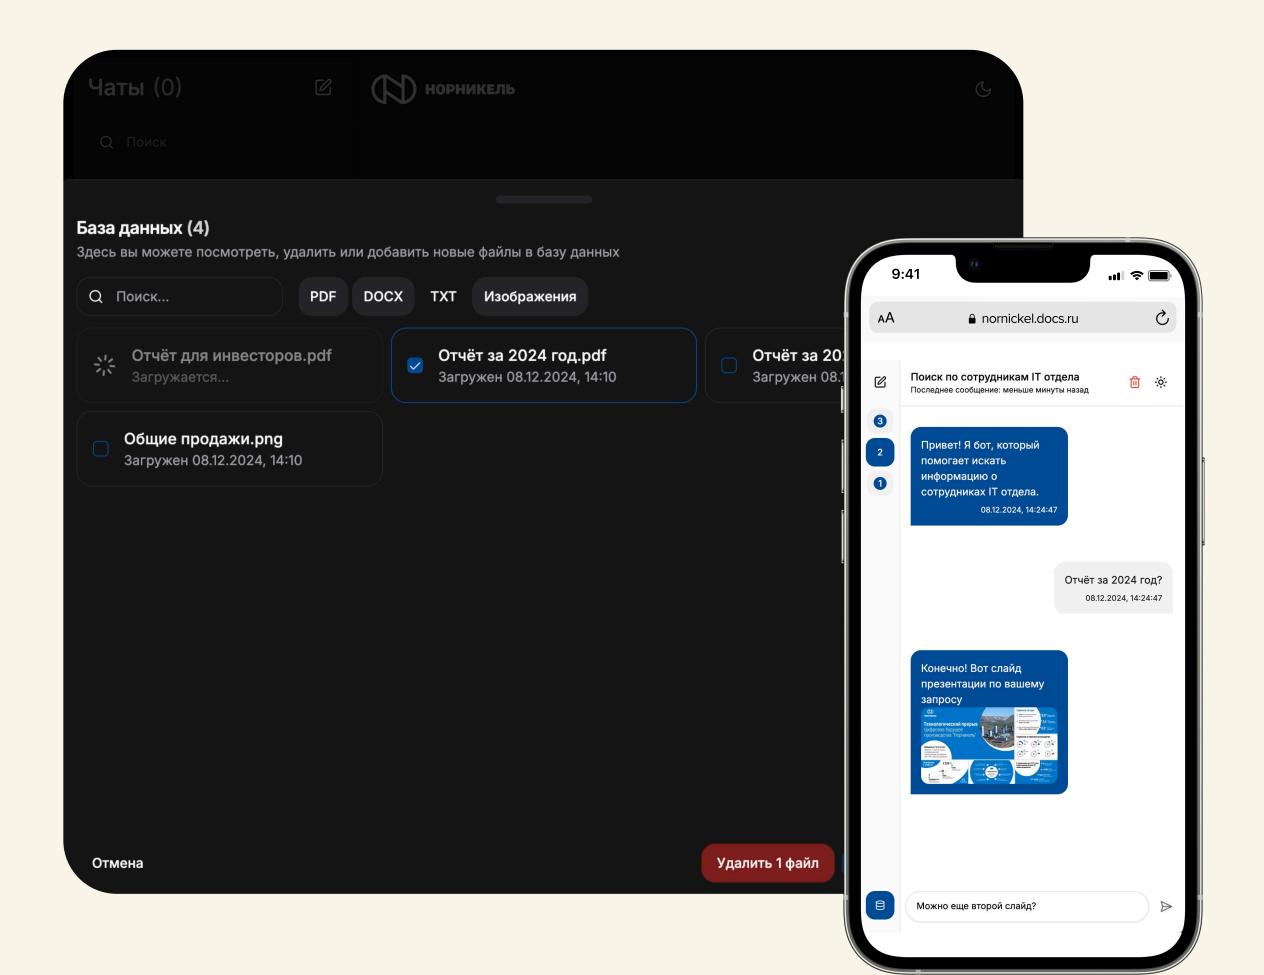




### в 1,5 меньше занятой памяти

достигнуто на одной карточке благодаря оптимизации кода

# Удобный интерфейс в виде чата



### Адаптивный интерфейс

Удобно добавлять документы и искать по ним информацию в любом месте, в любое время

#### Удобное добавление и удаление файлов

Файлы добавляются в ассинхронном режиме— добавляйте файлы и не ждите, пока они загрузятся

#### Интуитивно понятный и доступный интерфейс

Настроена доступность, а система чатов достаточно проста для пользователей, есть возможность открытия файлов и приближения картинок

Кирилл Киреев Даня Малинин Лёша Земцов Даня Кузнецов Лиза Тарасова ML Backend Product MLFrontend @malinin\_danila @biskwiq @lissey\_t @daniilda @zzmtsvv